上海创智学院 · 博士研究生开题报告

面向自我改进智能体的长程强化学习方法与系统研究

Long-Horizon Reinforcement Learning for Self-Improving Agents: Methods and Systems

报告人：路思远 · 专业 / 领域：人工智能 · 导师组组长：温颖 · 2026 年 10 月

专业背景：大模型智能体的强化学习后训练

教育背景

- 2025 – 至今　浙江大学 计算机科学与技术 博士在读
  西湖大学联合培养 · 人工智能方向
- 2021 – 2025　北京邮电大学 物联网工程 本科
  伦敦玛丽女王大学联合培养 · 均分 90.97 · 排名 7 / 182

研究经历

- **蚂蚁集团 AWorld 团队 · 研究实习** 2025.06 – 2026.06
  多轮工具调用的强化学习后训练：冷启动、信用分配、经验生成
- **上海创智学院科研轮转 · 导师 刘鹏飞** 2026.03 – 2026.09
  SWE 环境规模化合成 · 异步多轮 RL 框架；两项考核均为优秀

代表性成果 （* 共同第一作者）

Don't Just Fine-tune the Agent, Tune the Environment
ICLR 2026 · 共同第一作者*（署名第一）· Environment Tuning

Teach the Magnitude, Not the Direction
EMNLP 2026 主会 · 共同第一作者* · CrEST

AWorld: Orchestrating the Training Recipe for Agentic AI
技术报告 · 共同第一作者*

开源　T3RL 作者（50+ stars）· AWorld 贡献者（1.2k stars）

研究主线　多轮工具调用 RL：ET · CrEST → 规模化经验生成：AWorld · T3RL → 长程 SWE：环境合成 · 异步 RL → 本课题：长程 + 自我改进

递归自我改进：从设想走向工程实践

> 超智能机器能够设计出更好的机器——「最后一项需要人类完成的发明」
>
> I. J. Good, 1965 [1]

> AI 用当前的智能，改进产生其智能的认知机制
>
> Yudkowsky, 2008 · Recursive Self-Improvement (RSI)

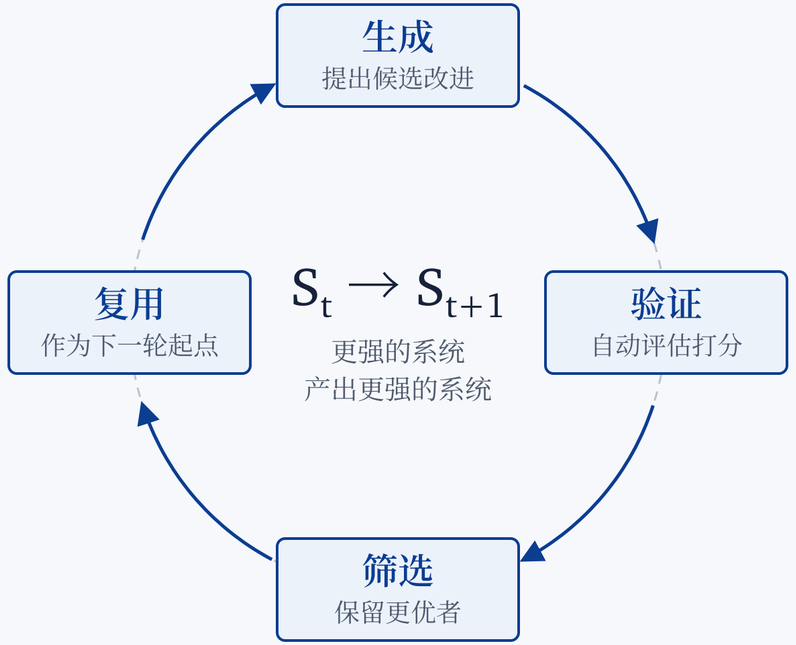
大模型智能体在编程、科研等数字化任务上快速进步，这一反馈回路开始可测量：

1% → 26%

某前沿 AI 企业内部研发中，由 AI 在仅有高层监督下独立完成的比例（2026.03 → 2026.08）[3]

7 → 3 个月

AI 可完成任务时长的翻倍周期，2024 年以来明显加速 [3]



被改进的对象：任务解 · 智能体代码 · 探索策略 · 模型权重？

现有自我改进回路：改进停留在权重之外



原作者：权重进入回路是下一步，但代价高

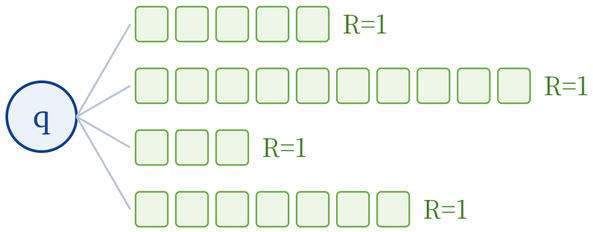
- AlphaEvolve：发现 4×4 复矩阵乘法的 48 次标量乘法算法；作者将「把增强能力蒸馏回下一代基座」列为下一步，改进自身的反馈周期**以月计** [4]
- DGM：SWE-bench 由 20.0% 升至 50.0%；「改写训练脚本、更新基础模型」留作未来工作，仅改代码一次运行约**两周** [5]
- ThetaEvolve / TTT-Discover：权重进入回路确有收益，但 RL 单元是「一次提示—一次生成—一个分数」 [7,8]
- Lilian Weng：完整的自我改进需让模型同时更新权重；训练稳定性、Goodhart 效应等仍是开放问题 [Weng, 2026]

缺口：以多步智能体形式运行的长程改进回路，尚未实现有效的权重更新。

权重进入回路，本质是长程智能体强化学习

成百上千轮「提议—执行—评估」 → 每轮多步交互：读代码 · 跑实验 · 改实现 → 奖励稀疏、高度延迟 → **典型的长程决策任务**

算法瓶颈：组内比较 + 轨迹级信号



等待最慢轨迹

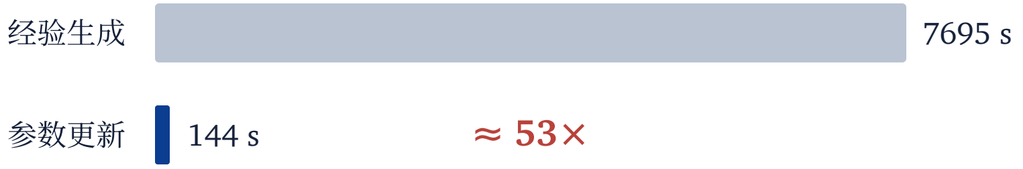
$\mu = 1, \sigma = 0$

⇒ 优势全部为 0

同一轨迹各步共享同一优势

- 以 GRPO 为代表的组相对方法需对同一任务采样一组轨迹：组内耗时差异大，整组全对 / 全错时信号归零 [9,10]
- 无价值函数，只有轨迹级优势：稀疏的终局奖励难以分配到具体步骤

系统瓶颈：经验生成远慢于参数更新



GAIA 训练，单节点顺序执行一轮「采样—训练」的耗时 [11]

- 长程任务中大量算力等待最慢的轨迹，训练侧长时间空闲
- 训推解耦的异步执行可提升吞吐，但引入策略滞后与离策略偏差，损害稳定性 [12]

二者相互耦合：异步执行要求算法容忍离策略数据；放弃分组采样又要求更可靠的价值估计 —— **算法—系统协同设计**是本课题的出发点。

研究目标与关键科学问题

自我改进智能体：利用自身与环境交互产生的经验和信号**更新模型权重**，使下一轮能力由当前能力所生成的训练信号决定。

总体目标：研究长程智能体任务上的高效强化学习方法与系统，使模型权重能够**以可接受的代价进入长程自我改进回路**。

科学问题一 · 对应研究内容一

单条轨迹上的步级信用分配

长程、仅有终局奖励时，如何在单条轨迹上实现**低方差的步级信用分配**?

难点：不依赖分组、逐轮验证与外部教师，获得足够准确的状态价值估计；价值模型冷启动，长序列夹杂环境观测、结构不一

目标　样本效率（达到同等性能所需的交互量）与最终性能优于 GRPO 类方法

科学问题二 · 对应研究内容二

异步训练的效率—稳定性平衡

经验生成与参数更新解耦后，如何在效率与稳定性之间取得**可控的平衡**?

难点：一条长轨迹由多个版本的策略先后生成；序列级重要性权重随长度近似指数退化；训推数值不一致、沙箱故障放大偏差

目标　训练稳定前提下，单位时间有效训练样本量显著高于同步训练，缩短墙钟时间

科学问题三 · 对应研究内容三

回路经验 → 下一轮训练信号

自我改进回路产生的**非平稳、多策略经验**，能否以及如何转化为下一轮的有效训练信号?

难点：环境状态随回路不断变化，同一状态往往只有一条反馈、评估代价高；需防止回路自身的偏差放大与奖励投机

目标　在至少一类长程自我改进场景中闭合权重层回路，效率与效果优于冻结权重的回路

技术路线

研究基础（已发表工作）

Environment Tuning
ICLR 2026 · 环境反馈 · 课程学习 · 进度奖励

CrEST
EMNLP 2026 · 轮次级信用分配 · 自教师信号

AWorld / T3RL
技术报告 · 开源框架 · 分布式经验生成 · 多轮训练框架

研究内容一：面向单轨迹、终局奖励的长程信用分配

科学问题一

- 以状态价值估计取代组内比较
- 面向智能体轨迹的价值模型与训练目标
- 多版本策略经验驱动的价值预训练
- 统计式基线作为过渡与兜底

相互约束

研究内容二：异步长程训练系统

科学问题二

- 训推解耦的异步经验生成
- 策略滞后下的离策略修正
- 长轨迹资源管理与故障恢复

场景需求反馈

研究内容三：算法—系统协同设计与自我改进场景验证

科学问题三

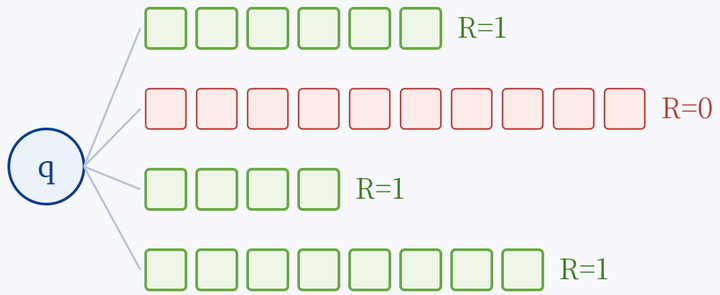
- 离策略数据、价值估计与采样调度联合设计
- 价值估计扩展到回路中非平稳、多版本的经验
- 闭合权重层回路，对比冻结权重回路

目标：自我改进智能体

让模型权重以可接受的代价进入长程自我改进回路

研究内容一：以状态价值估计取代组内比较

组相对基线（GRPO；前期 ET / CrEST 的轮次级变体）



$A_i = (R_i - \mu) / \sigma$

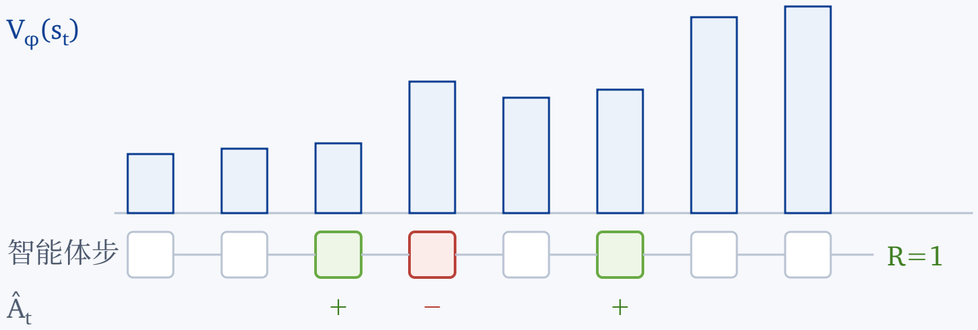
· 每个任务需 G 条轨迹

· 同一轨迹各步共享优势

· 全对 / 全错 ⇒ 优势为 0

· 轮次级需轮次对齐、逐轮验证

状态价值估计（本课题：单条轨迹即可）



价值跃迁处获得信用：无需分组、无需逐轮验证、无需外部教师

① 价值模型

面向「模型输出—环境观测」交替、长度与结构不一的智能体轨迹，研究输入表示、训练目标与步级优势的计算[12]

② 价值预训练

用训练过程中各版本策略产生的轨迹预训练并持续更新价值模型——多样策略经验缓解冷启动[34]

③ 过渡与兜底

以跨迭代（SPO）、跨任务批内（BASIS）统计基线过渡；必要时与组内基线自适应切换[10,32]

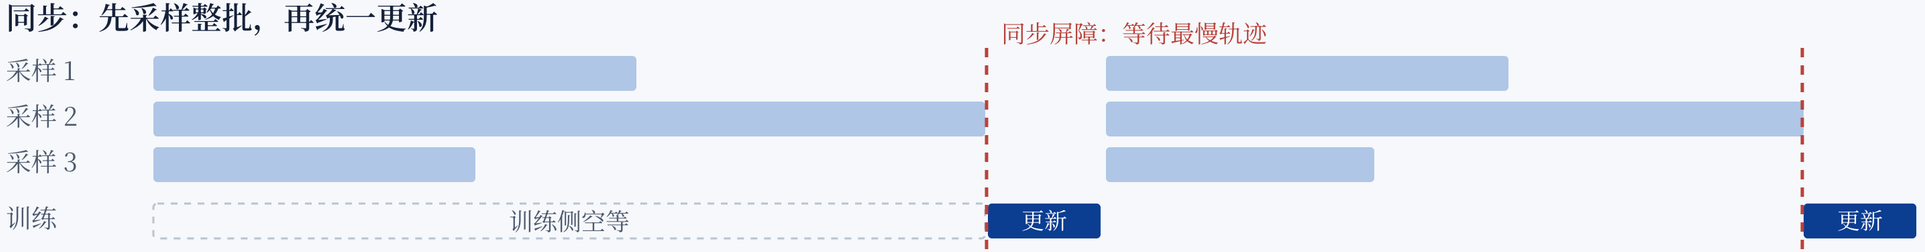
$$\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t), \quad \hat{A}_t = \sum_{l \geq 0} (\gamma\lambda)^l \, \delta_{t+l}$$

起点：PPO + GAE 的步级优势[29,30]，t 以智能体步为单位

预期：不依赖分组采样、逐轮验证与外部教师，样本效率与最终性能优于 GRPO 类及前期轮次级方法。

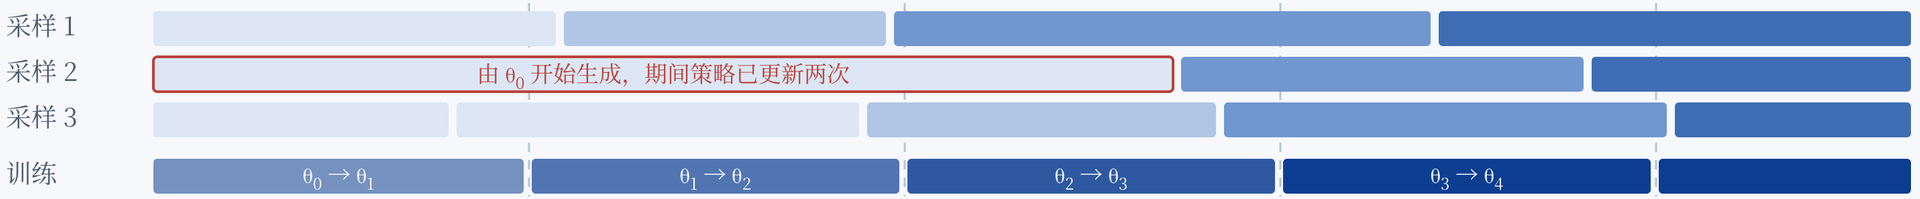
研究内容二：训推解耦的异步长程训练系统

同步：先采样整批，再统一更新



GPU 利用率低

异步：轨迹完成即入队，训练持续进行



吞吐 ↑
策略滞后 ↑
离策略偏差 ↑

① 异步经验生成

轨迹完成即进入训练队列，不再等待整批或整组采样结束

② 离策略修正

基于推理侧对数概率的 token 级重要性采样与双侧裁剪；限制陈旧度上限，逐步放开异步程度

③ 长轨迹管理

长轨迹的上下文与显存管理，支撑更长的交互序列

④ 沙箱调度与容错

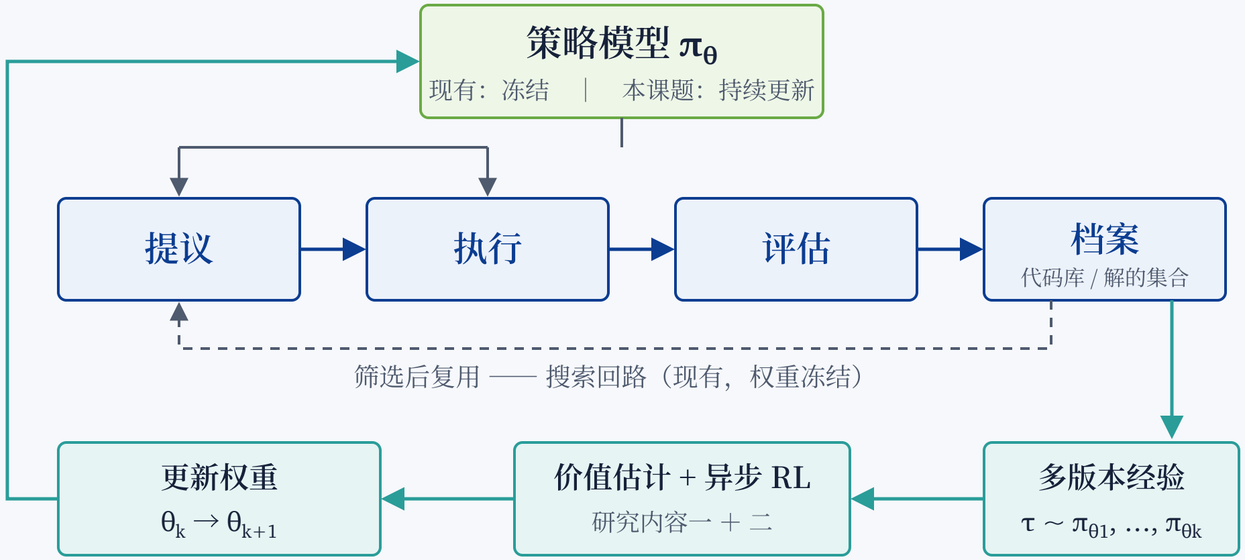
大规模沙箱的调度、故障检测与恢复，降低系统引入的数据噪声

$$\rho_t = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\text{rollout}}(a_t \mid s_t)} \qquad \tilde{\rho}_t = \text{clip}\left(\rho_t,\, 1-\epsilon_{\text{low}},\, 1+\epsilon_{\text{high}}\right)$$

基础：AWorld 分布式沙箱（14.6×）· T3RL token 级对齐 · 异步多轮框架 siirl-agentic

警示：异步训练中标准 GRPO 约 160 步即崩溃[12]——稳定性须与效率一起设计

研究内容三：协同设计，闭合权重层自我改进回路



学习回路：经验 → 训练信号 → 权重（本课题）

协同设计

- 系统的异步程度决定离策略偏差，进而决定价值估计与重要性修正的要求
- 单轨迹信号的需求，反过来决定采样与调度方式

场景验证

- 回路中环境状态（代码库、解的档案）不断变化，同一状态往往只有一条反馈
- 用回路积累的多版本策略轨迹预训练价值模型，以 RL 更新权重 [12,34]
- 对照冻结权重的回路，比较**改进效率**与**最终效果**；先在评估快的短任务验证，再扩展长度

安全约束

- 可验证奖励作为信用分配的最终依据，评估器置于回路之外，抑制偏差放大与奖励投机

创新点

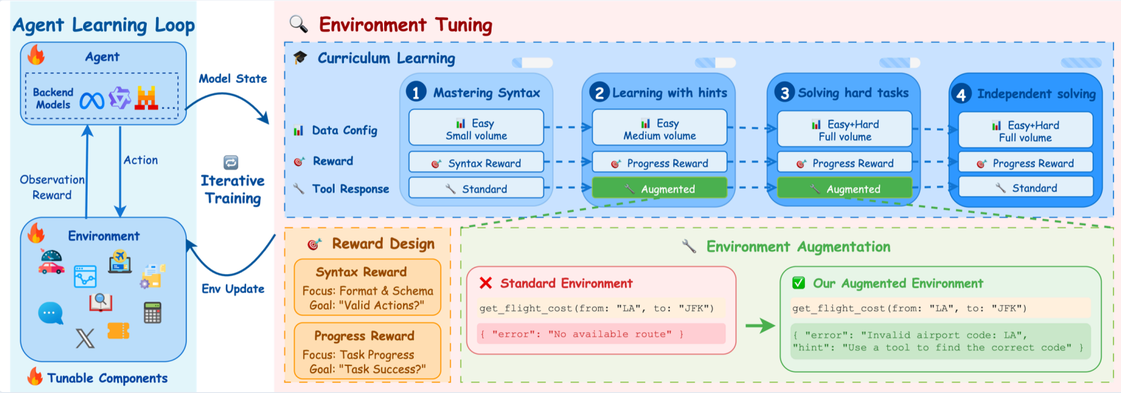
		现有工作		本课题
01	问题定位	冻结权重的**搜索回路**：在权重不变的前提下改进任务解、代码或探索策略	→	权重层的**学习回路**：把自我改进视为长程智能体任务，以「当前能力生成下一轮训练信号」组织算法与系统，使模型权重成为被持续改进的对象
02	信用分配	**组内比较** + 逐轮可验证奖励，包括申请人前期的轮次级方法 ET / CrEST	→	基于**状态价值**的长程信用分配：面向结构不一的智能体轨迹设计价值估计，以多版本策略经验训练并持续更新价值模型，单条轨迹获得低方差的步级信用
03	训练系统	单纯追求吞吐的异步系统；以同步训练为前提的算法改进——二者割裂	→	**算法—系统协同设计**：离策略修正、价值估计与异步经验生成作为整体设计，在稳定前提下提升长程训练效率，并闭合权重层回路

三点合起来回答一个问题：**如何让模型权重以可接受的代价进入长程自我改进回路**。

前期基础一：从环境反馈中稳定学习，细粒度信用分配

Environment Tuning

ICLR 2026 · 共同第一作者*



7.00→36.92
Qwen2.5-7B，BFCL V3 多轮准确率（%）

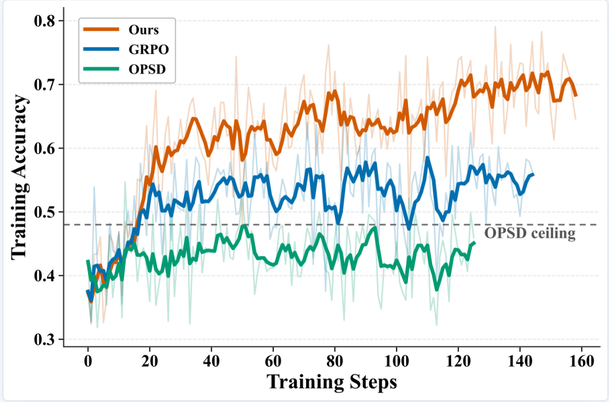
54.34
watt-tool-8B，超过 GPT-4o 51.00、o3 49.25

400
个问题实例训练，无需专家轨迹

单阶段 GRPO 仅 17.42%，约 70 步梯度爆炸；课程 + 环境增强 + 逐轮进度奖励使训练稳定[13]

CrEST

EMNLP 2026 主会 · 共同第一作者*



BFCL V3 训练曲线（Qwen3-4B）

52.00
Qwen3-4B，BFCL V3；GRPO 43.63 · 自蒸馏 OPSD 38.75

13 / 14
项指标最佳或并列最佳（2 规模 × 2 基准）

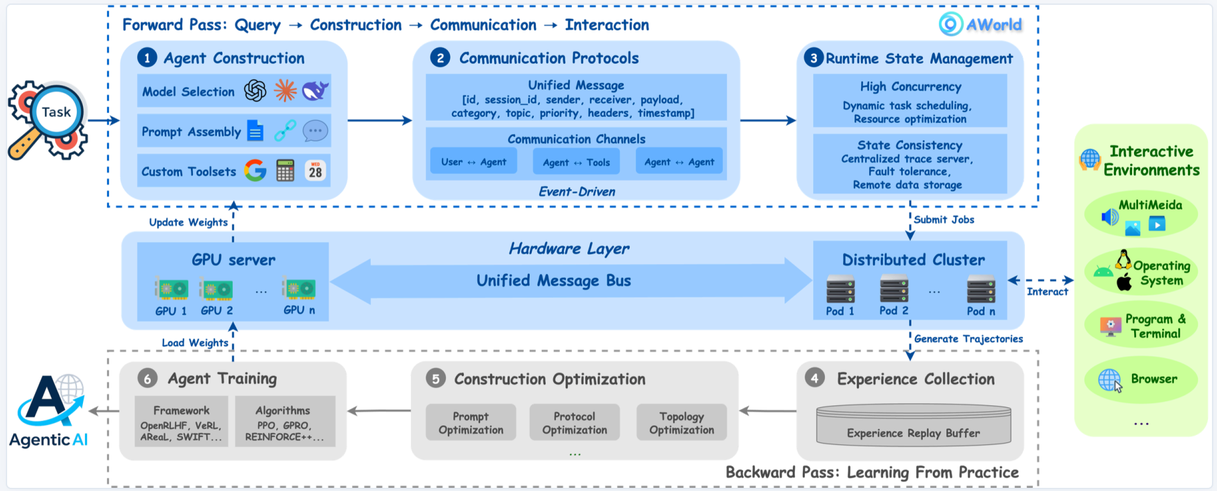
验证器定方向、自教师定幅度：仅轮次拆分 47.88、仅 token 调制 48.75，二者结合 52.00；约 20 步即超过 OPSD 上限[14]

启示：只有问题实例、没有专家轨迹时，模型能依靠环境反馈从自身经验中稳定学习——这正是自我改进的基本形态。局限：依赖分组采样、轮次对齐与逐轮验证 → 研究内容一。

前期基础二：规模化经验生成与长程训练系统

AWorld

技术报告 · 共同第一作者*



14.6×
一轮 rollout：7695 s → 525 s（分布式执行）

32.23%
Qwen3-32B GAIA pass@1（原 21.59），超过 GPT-4o 27.91

12→32
未参与训练的 xbench-DeepSearch，泛化提升

科研轮转

导师 刘鹏飞 · 两项均为优秀

真实场景 Agent Training

SWE 环境合成管线：智能体自动完成仓库探索、任务构建与验证，已稳定合成**数十万**可复现环境；仅用 900 余个环境的轨迹做 SFT，Qwen3-30B-A3B 在 SWE-bench Verified 达 57%

大模型 RL × infra 联合优化

异步多轮 RL 框架 siirl-agentic（MPMD：数据调度 / 多轮 rollout / 分布式训练解耦）；打通 SWE-agent → E2B 沙箱链路，实现沙箱失效检测与重建；完成 Qwen3-4B/8B 的 SWE-bench GRPO 训练验证，改进均已合入主线

开源 T3RL：多轮训练中 log-prob、loss mask 与响应长度严格 token 级对齐

前期边界 → 出发点

依赖分组采样与逐轮验证 → **研究内容一**

「先采样、后更新」的同步训练 → **研究内容二**

任务长度中等 → **研究内容三**

预期成果

3–4 篇

学术论文

人工智能领域高水平会议或期刊；每项研究内容至少 1 篇

1 套

开源系统

面向长程智能体的异步 RL 训练框架，配套训练代码与模型权重

2 项

方法与原型

单轨迹、终局奖励的长程信用分配方法；闭合权重层回路的自我改进系统原型

1 篇

学位论文

完成博士学位论文

如何检验：每项内容都有明确的对照与指标

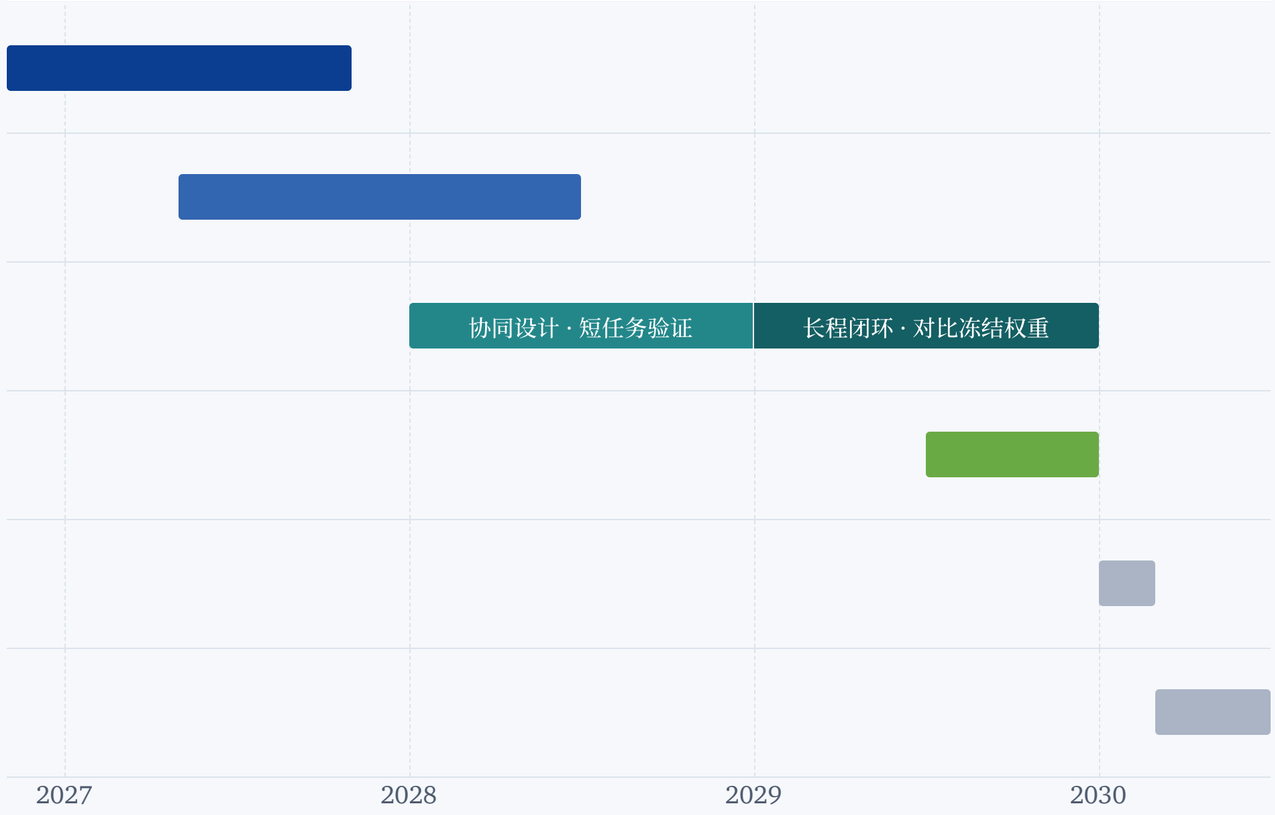
研究内容	对照	核心指标
一 · **信用分配**	GRPO 类；前期 ET / CrEST	样本效率（达到同等性能所需的环境交互量）· 最终性能
二 · **训练系统**	同步训练	训练稳定性 · 单位时间有效训练样本量 · 墙钟时间
三 · **自我改进**	冻结权重的回路	改进效率 · 最终效果

评测基准：BFCL · τ^2-bench · GAIA · SWE-bench，均公开可用

模型规模：前期已在 4B–32B 上完成 RL 训练，学院与团队算力可支撑同等规模实验

研究进度安排

阶段	2026.11 – 2030.06	阶段性成果
研究内容一：长程信用分配 2026.11 – 2027.10		信用分配方法与对比验证；论文 1 篇
研究内容二：异步训练系统 2027.05 – 2028.06		异步长程 RL 框架开源；论文 1 篇
研究内容三：协同设计与场景验证 2028.01 – 2029.12	协同设计 · 短任务验证 / 长程闭环 · 对比冻结权重	权重层回路原型；论文 1–2 篇
综合实验验证与成果整理 2029.07 – 2029.12		更大规模评测；发布代码与权重
学位论文撰写 2030.01 – 2030.02		学位论文初稿
修改、预答辩、送审与答辩 2030.03 – 2030.06		学位论文定稿，完成答辩



交叉安排：研究内容一形成方法原型后启动二，按价值估计的需求设计系统；异步框架可用后启动三，用两年完成短任务验证与长程闭环。

当前进展：三项前期工作（ET · CrEST · AWorld）已发表或公开，两项科研轮转已完成——研究内容一可于 2026.11 直接启动。

谢谢各位老师

恳请批评指正

路思远 · lusiyuanzs@gmail.com · github.com/IcyFish332

可行性分析与风险对策

可行性

- **理论基础**：策略梯度、优势估计与价值函数学习（PPO、GAE）及离策略重要性采样均有成熟理论；单轨迹优化与异步训练已有初步方法与实证 [10,12,37]
- **前期基础**：冷启动与稀疏奖励、细粒度信用分配、大规模经验生成三个环节均已验证，方法与代码可复用
- **技术条件**：熟悉 SGLang、vLLM 推理引擎与 verl、slime 训练框架；T3RL 作者、AWorld 贡献者
- **计算资源**：前期已在 4B–32B 模型上完成 RL 训练；依托团队与学院平台

风险与对策

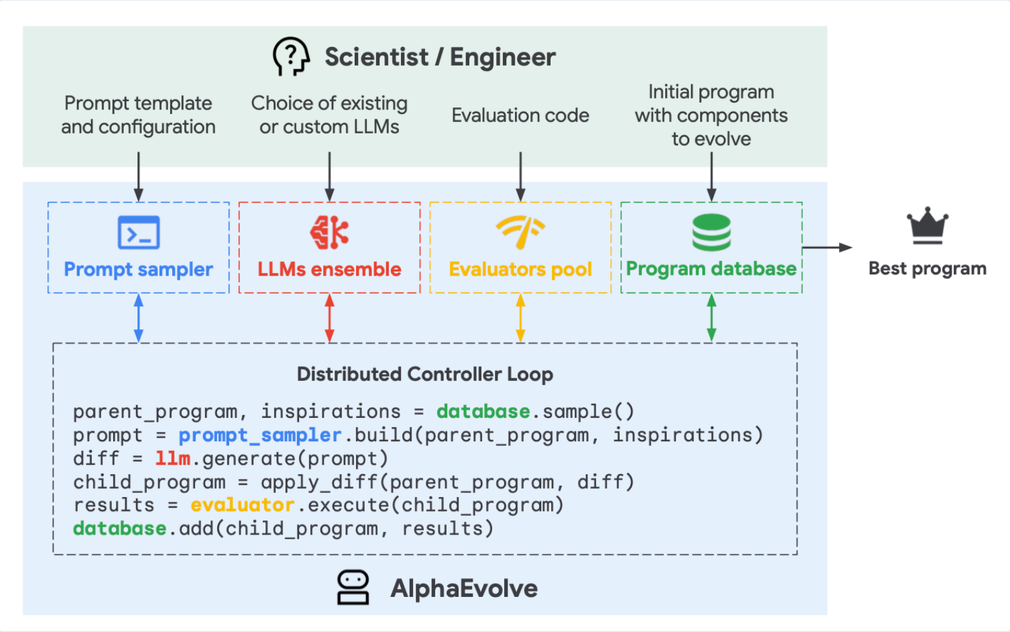
风险	对策
长程价值函数难以训练	退回跨迭代、跨任务的统计式基线，或在价值估计与组内基线之间自适应切换
异步训练不稳定	限制数据陈旧度上限，采用更严格的 token 级裁剪，逐步放开异步程度
自我改进场景评估成本高	先在任务较短、评估较快的场景验证方法，再逐步扩展任务长度
出现新的训练范式	科学问题仍然成立，具体方法随之更新

长程反馈下的信用分配：现有方法族对比

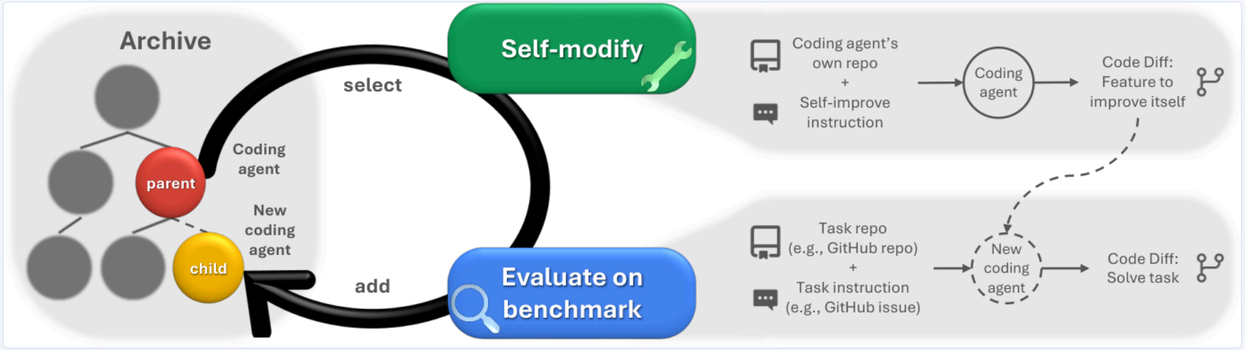
方法族	代表工作	需分组采样	信号粒度	主要局限
组相对	GRPO · DAPO · GiGPO · MT-GRPO	是	轨迹 / 步 / 轮次	长程下组内同步等待、退化组；轮次级要求轮次对齐与逐轮验证 [9,20,25,26]
教师信号	OPD · OPSD · CrEST	视方法而定	token 级	性能上限受教师约束；OPSD 约 77% 梯度集中在前 5% 的 token；CrEST 以验证器限定方向 [14,27,28]
价值函数	PPO + GAE · VAPO	否	token / 步级	价值模型冷启动；长程、多轮智能体轨迹上拟合困难，缺乏系统验证 [29–31]
单轨迹	SPO · BASIS · SR-PPO · SAO	否	轨迹 / token 级	以跨迭代 / 批内统计或学习的价值替代组内基线；价值冷启动仍是瓶颈 [10,12,32,33]
本课题	**状态价值 + 多版本经验预训练 + 统计基线兜底**	**否**	**智能体步级**	**面向非平稳、多策略的自我改进经验，与异步系统协同设计**

连续控制中的证据：仅用单一策略数据预训练的价值函数与微调目标不匹配，需要多样策略的经验 [34]——这正是自我改进回路天然积累的数据。

代表性系统：生成—验证—筛选—复用，权重冻结



AlphaEvolve：冻结的 LLM 集成生成代码 diff，评估器打分，程序数据库筛选复用[4]（图源：Novikov et al., 2025）



DGM：编码智能体改写自身代码，基准评测后加入档案（图源：Zhang et al., 2025）[5]

- AlphaEvolve：4×4 复矩阵乘法 48 次标量乘法；优化了训练自身底层模型的计算内核
- DGM：SWE-bench 20.0% → 50.0%；以基准结果作为改进有益的经验证据
- Dream-RSI：把历史发现过程组织为回放模拟器，低成本改进探索策略[6]
- 共同点：被改进的是任务解、智能体代码与探索策略，**底层模型权重始终冻结**

初步实验结果：Environment Tuning 与 CrEST

表 1　BFCL V3 多轮平均准确率（%）[13]

基座模型	训练前	+ToolRL	+ET
Qwen2.5-7B-Instruct	7.00	18.00	**36.92**
Llama-3.1-8B-Instruct	5.48	11.25	**28.25**
ToolACE-2-Llama-3.1-8B	37.99	33.75	**47.18**
watt-tool-8B	35.74	42.00	**54.34**

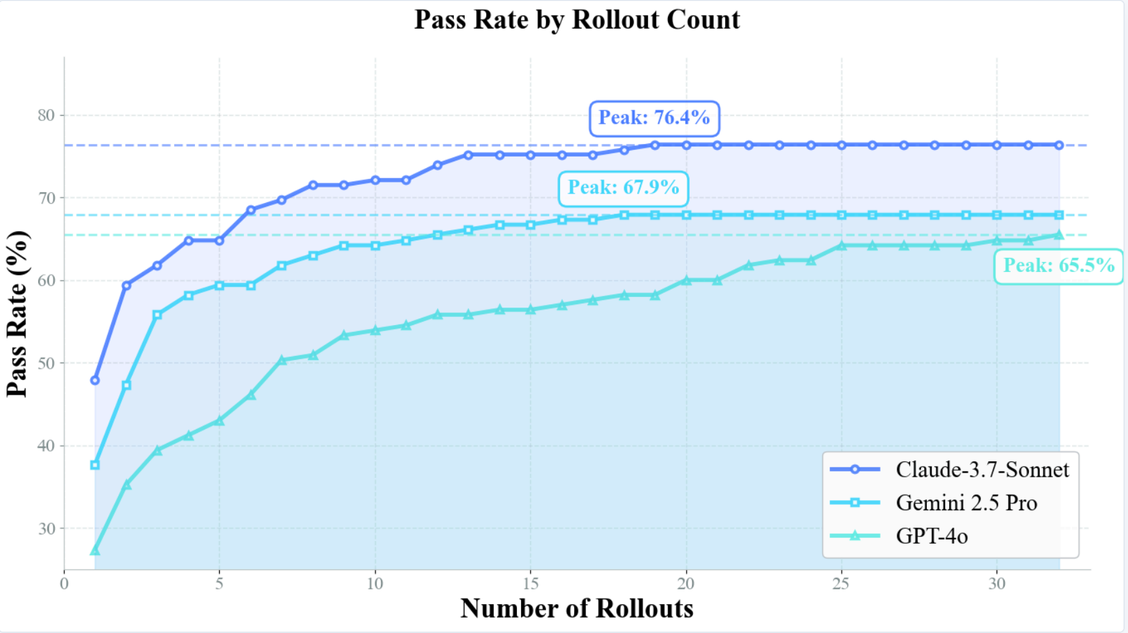
训练集 400 条（四类各 100），无专家轨迹；分布外 ACEBench：ToolACE-2 由 8.34 升至 15.00，直接 RL 降至 6.65。

表 2　CrEST 与基线对比（%）[14]

方法	4B · BFCL	4B · 会话	8B · BFCL	8B · 会话
基座模型	22.12	3.13	33.38	4.69
GRPO	43.63	4.69	43.25	5.47
MT-GRPO	49.25	6.25	44.00	7.03
Environment Tuning	47.25	4.69	46.00	7.81
OPD	44.50	6.25	44.75	3.91
OPSD	38.75	4.69	41.75	3.91
CrEST	**52.00**	**7.03**	**50.00**	**9.38**

会话：WildToolBench 会话级准确率；Qwen3-4B / 8B-Instruct，所有方法组大小 G = 16。

初步实验结果：AWorld 规模化经验生成



GAIA 验证集：通过率随 rollout 次数上升，GPT-4o 由 1 次的 27.3% 升至 32 次的 65.5%[11]

表 3　一轮「采样—训练」耗时（秒）[11]

执行方式	rollout	训练	总耗时
AWorld 分布式执行器	**525**	**144**	**669**
单节点顺序执行器	7695	144	7839

- 充足的经验生成是获得正向学习信号的前提
- Qwen3-32B：先以 886 条成功轨迹 SFT 缓解冷启动，再以 GRPO 训练（每题 32 条轨迹）
- GAIA 测试集 pass@1 由 21.59% 升至 32.23%，与 DeepSeek-V3（31.89%）相当；Level 3 达 16.33%，为所列模型最高

主要参考文献 （编号与开题报告一致）

[1] Good. Speculations concerning the first ultraintelligent machine. 1966.
[3] Chan et al. What if automating AI R&D triggers an intelligence explosion? 2026.
[4] Novikov et al. AlphaEvolve: a coding agent for scientific and algorithmic discovery. 2025.
[5] Zhang et al. Darwin Gödel Machine: open-ended evolution of self-improving agents. 2025.
[6] Zheng et al. Dream-RSI: recursive self-improvement through evolving worlds. 2026.
[7] Wang et al. ThetaEvolve: test-time learning on open problems. 2025.
[8] Yuksekgonul et al. Learning to discover at test time. 2026.
[9] Shao et al. DeepSeekMath (GRPO). 2024.
[10] Xu & Ding. Single-stream policy optimization. 2025.
[11] Yu*, Lu* et al. AWorld: orchestrating the training recipe for agentic AI. 2025.
[12] Hou et al. Single-rollout asynchronous optimization for agentic RL. 2026.
[13] Lu*, Wang* et al. Don't just fine-tune the agent, tune the environment. ICLR 2026.
[14] Wang*, Lu* et al. Teach the magnitude, not the direction. EMNLP 2026.
[16] Hu, Lu, Clune. Automated design of agentic systems. ICLR 2025.
[17] Zelikman et al. STaR: bootstrapping reasoning with reasoning. NeurIPS 2022.
[18] Huang et al. R-Zero: self-evolving reasoning LLM from zero data. ICLR 2026.
[20] Yu et al. DAPO. 2025.　[25] Feng et al. GiGPO. 2025.　[26] Wei et al. MT-GRPO. 2025.
[27] Lu, Thinking Machines Lab. On-policy distillation. 2025.
[28] Zhao et al. Self-distilled reasoner (OPSD). 2026.
[29] Schulman et al. Proximal policy optimization. 2017.
[30] Schulman et al. Generalized advantage estimation. ICLR 2016.
[31] Yue et al. VAPO. 2025.　[32] Gong et al. BASIS. 2026.
[33] Che et al. Learning with a single rollout via Monte Carlo Pass@k critic. 2026.
[34] Dong et al. Do you really need to pretrain Q-functions for online RL fine-tuning? 2026.
[37] Fu et al. AReaL: large-scale asynchronous RL for language reasoning. 2025.
[Weng, 2026] Weng. Harness engineering for self-improvement. Lil'Log, 2026.
Yudkowsky. Artificial intelligence as a positive and negative factor in global risk. 2008.